Οικονομικό Πανεπιστήμιο Αθηνών

Τμήμα Στατιστικής

Ανάλυση Δεδομένων

Ανάλυση στον REM ύπνο

(Εργασία 4)

Πέτρος Χριστοδούλου

s6210114

Διδάσκοντες : Ι. Ντζούφρας Κ. Πατέρας

27 Μαΐου 2024

Περιεχόμενα

1. Εισαγωγή - Περιγραφή και μελέτη προβλήματος

2. Περιγραφική ανάλυση

3. Σχέσεις μεταβλητών ανά δύο

   3.1 Σχέσεις μεταβλητών για όλο το δείγμα

   3.2 Σχέσεις μεταβλητών ανά necksize γκρουπ

4. Προβλεπτικά ή Ερμηνευτικά μοντέλα

   4.1 Επιλογή μοντέλου

   4.2 Έλεγχος μοντέλου

   4.2.1 Κανονικότητα

   4.2.2 Ομοσκεδαστικότητα

   4.2.3 Ανεξαρτησία

   4.2.4 Γραμμικότητα

5. Συμπεράσματα και Συζήτηση

- Αναφορές

- Παράρτημα

1 Εισαγωγή - Περιγραφή και μελέτη προβλήματος

Ο κόσμος έχει αλλάξει. Η καθημερινότητα του σήμερα δεν μπορεί πλέον να συγκριθεί ακόμη και με εκείνη των ανθρώπων 20 χρόνια πριν. Ο τρόπος με τον οποίο οι άνθρωποι εργάζονται, επικοινωνούν, ακόμη και ο τρόπος με τον οποίο τρέφονται διαφέρει αισθητά. Μαζί με αυτά ,έχουν αλλάξει και οι ανάγκες μας. Αυτό όμως που παραμένει σταθερό, είναι η ανάγκη του ανθρώπου για ύπνο και ως επέκταση, οι επιρροή που έχει στο σώμα και στην ψυχολογία μας. Πιο συγκεκριμένα, ο ύπνος REM, το στάδιο του ύπνου στο οποίο βλέπουμε όνειρα, θεωρείται μαζί με το τρίτο στάδιο του nREM, το πιο σημαντικό στάδιο του ύπνου καθώς βοηθάει στην μνήμη ,στην σωματική αποκατάσταση, στην ρύθμιση των συναισθημάτων και στην ψυχική υγεία. Αντιθέτως, όπως αναφέρεται στο Nursing Forum: Vol 57, Issue 1[5], έλλειψη REM ύπνου έχει ως αποτελέσματα εξάντληση, οξυθυμία, μειωμένα αντανακλαστικά καθώς και άλλα τα οποία αναφέρονται στο άρθρο. Πώς όμως επηρεάζεται ο REM ύπνος κάθε ατόμου;

Σε αυτή τη μελέτη θα αναλύσουμε διάφορους παράγοντες οι οποίοι ενδέχεται να επηρεάζουν τον REM ύπνο προκειμένου, να εντοπίσουμε αυτούς οι οποίοι παίζουν τον πιο καθοριστικό ρόλο και στην συνέχεια, θα φτιάξουμε ένα ερμηνευτικό μοντέλο το οποίο θα μας παρέχει γνώση της ποσότητας REM ύπνου κάθε ατόμου βάση των καθοριστικών αυτών παραγόντων. Δεδομένου της σημαντικότητας που κατέχει ο REM ύπνος,αυτή η μελέτη μπορεί να βοηθήσει στην βελτίωση των συνθηκών που εμποδίζουν ένα άτομο από το να βιώνει έναν ικανοποιητικό REM ύπνο και ως εκ' τούτου βελτίωση της καθημερινότητάς του. Η μελέτη θα γίνει με την βοήθεια ενός σετ δεδομένων το οποίο, θα μας παρέχει πληροφορίες όσον αφορά τις ατομικές συνήθειες και χαρακτηριστικά 106 ατόμων βάση 9 διαφορετικών μεταβλητών ενώ, όλοι οι έλεγχοι θα γίνουν για α=5% επίπεδο σημαντικότητας. Οι μεταβλητές είναι:

Όνομα μεταβλητής	Τύπος μεταβλητής	Ερμηνεία	Τιμές
1. Age	Αριθμητική	Ηλικία του ατόμου	
2. Gender	Κατηγορική	Φύλο του ατόμου	1=γυναίκα, 0=άνδρας
3. BMI	Αριθμητική	Δείκτης μάζας σώματος	
4. Necksize	Αριθμητική	Περίμετρος λαιμού (cm)	
5. Sbp	Αριθμητική	Συστολική πίεση αίματος (mmHg)	
6. Alcohol	Κατηγορική	Χρήση αλκοόλ	1=ναι, 0=όχι
7. Caffeine	Κατηγορική	Χρήση καφεΐνης	1=ναι, 0=όχι
8. REM	Αριθμητική	Ποσοστό REM ύπνου	
9. AI	Αριθμητική	Δείκτης ξυπνημάτων	

Πίνακας 1: Πίνακας Δεδομένων

2 Περιγραφική ανάλυση

Χρησιμοποιώντας το στατιστικό πακέτο R καθώς και τις διάφορες βιβλιοθήκες που μας προσφέρει, θα προβούμε σε ανάλυση των δεδομένων αξιοποιώντας τα ανάλογα γραφήματα καθώς και ελέγχους προκειμένου, να μπορέσουμε να παρέχουμε μια κατάλληλη ερμηνεία στα αποτελέσματά μας. Εισάγοντας τα δεδομένα παρατηρούμε τα εξής: οι μεταβλητές gender, alcohol και caffeine είναι κατηγορικές δηλαδή, χωρίζουν το δείγμα βάση των επιπέδων που έχει η κάθε μεταβλητή. Παρόλα αυτά, η R αναγνωρίζει τις συγκεκριμένες μεταβλητές ως μεταβλητές ακέραιων αριθμών. Ύστερα από μετατροπή των τριών αυτών μεταβλητών σε κατηγορικές καταλήγουμε πως: η μεταβλητή gender έχει δύο επίπεδα :όπου 1: woman και όπου 0: man ενώ για τις άλλες δύο η τιμή 1 συνεπάγεται χρήση της ουσίας ενώ η τιμή 0 συνεπάγεται την μη-χρήση της. Τέλος, φτιάχνουμε την δίτιμη μεταβλητή necksize η οποία μέσω χρήσης της διαμέσου της συγκεκριμένης μεταβλητής, χωρίζει το δείγμα σε 2 πληθυσμούς. Έτσι, η δίτιμη μεταβλητή μας δίνει τις τιμές 1 για άτομα με περίμετρο λαιμού μεγαλύτερης του 37.5 και 0 για άτομα με περίμετρο μικρότερης του 37.5, όπου 37.5 η διάμεσος του δείγματος.

Από τις κατηγορικές μεταβλητές παρατηρούμε ότι: Το δείγμα αποτελείται από 55 άντρες και 51 γυναίκες. 89 από τους 106 δεν καταναλώνουν αλκοόλ ενώ 82 καταναλώνουν καφεΐνη. Από τους 17 που καταναλώνουν αλκοόλ, 13 είναι γυναίκες ενώ φαίνεται πως, καφεΐνη καταναλώνουν τόσο οι άντρες όσο και οι γυναίκες με 38 γυναίκες έναντι 44 αντρών.

Όσον αφορά τις ποσοτικές μεταβλητές παρατηρούμε πως καμία δεν φαίνεται να είναι κανονική. Αυτό το βλέπουμε τόσο από την μη-μηδενική κύρτωση σε κάθε μεταβλητή όσο και από την μη-μηδενική ασυμμετρία. Παρόλα αυτά, σε κάποιες μεταβλητές η ασυμμετρία και η κύρτωση δεν απέχουν πολύ από το 0 ενώ, οι μέσοι μερικών μεταβλητών δεν διαφέρουν κατά πολύ από τους διάμεσους. Συμπεραίνουμε πώς, δεν μπορούμε να είμαστε σίγουροι για την κανονικότητα των μεταβλητών μας χωρίς να διεξάγουμε τα ανάλογα τεστ. Αναλυτικά οι μεταβλητές:

Μεταβλητή	Μέσος	Τυπική απόκλιση	Διάμεσος	Mad	Ελάχιστη τιμή	Μέγιστη τιμή	Ασυμμετρία	Κύρτωση
age	44.04	16.91	44.0	17.79	13.0	86.0	0.29	-0.53
BMI	28.01	5.78	27.0	4.45	17.0	46.0	0.77	0.42
necksize	37.55	4.58	37.50	5.19	30.0	50.0	0.36	-0.41
sbp	121.97	15.38	120.0	14.83	85.0	165.0	0.50	0.33
REM	0.14	0.08	0.14	0.09	0.0	0.33	0.13	-0.56
AI	18.35	15.08	14.80	8.67	3.5	121.80	118.30	3.71

Πίνακας 2: Χαρακτηριστικά των ποσοτικών μεταβλητών

Δεδομένου ότι το δείγμα μας είναι αρκετά μεγάλο (>50), οι έλεγχοι που θα χρειαστεί να κάνουμε είναι ο Shapiro-Wilk καί ο Kolmogorov-Smirnov με την διόρθωση Lilliefors. Διεξάγοντας τους ελέγχους μαθαίνουμε ότι, οι μεταβλητές οι οποίες τηρούν την κανονικότητα είναι η age (S-W p-value: $0.1401 > 0.05$ και K-S p-value: $0.3651 > 0.05$) και η REM (S-W p=value: $0.2365 > 0.05$ και K-S $p - value : 0.6389 > 0.05$) ενώ στις υπόλοιπες μεταβλητές τα p-value είναι μικρότερα του α=0.05 άρα, οδηγούμαστε σε απόρριψη της κανονικότητας τους.

3 Σχέσεις μεταβλητών ανά δύο

3.1 Σχέσεις μεταβλητών για όλο το δείγμα

Όπως αναφέρθηκε προηγουμένως, σκοπός της μελέτης είναι να μάθουμε ποιοι παράγοντες επηρεάζουν τον REM ύπνο. Προκειμένου να πετύχουμε το παραπάνω θα χρειαστεί πρώτα, να αναλύσουμε την αλληλεπίδραση των μεταβλητών μεταξύ τους ανά ζεύγη. Για την διερεύνηση των αλληλεπιδράσεων των ποσοτικών μεταβλητών μπορούμε να φτιάξουμε το Spearman correlation matrix το οποίο προτιμάμε καθώς μόνο δύο μεταβλητές είναι κανονικές. Δημιουργώντας το αποκτάμε τον εξής πίνακα συσχετίσεων:

	age	BMI	necksize	sbp	REM	AI
age	1					
BMI	0.06395	1				
necksize	0.06419	0.632	1			
sbp	0.1648	0.3855	0.3070	1		
REM	-0.2141	-0.0395	0.0389	-0.0984	1	
AI	0.3056	0.1287	0.2251	0.3586	-0.3279	1

Πίνακας 3: Πίνακας συσχετίσεων του Spearman

Παρατηρούμε ότι, για κατά απόλυτη τιμή, οι συσχετίσεις οι οποίες είναι μεγαλύτερες του 0.3 είναι για τα ζεύγη necksize-BMI, sbp-BMI, sbp-necksize, age-AI, AI-sbp, AI-REM. Για τις μεταβλητές REM και age, εφόσον είναι κανονικές κοιτάμε το Pearson correlation και ύστερα τεστάρουμε με cor.test. Βρίσκουμε ότι, cor(REM age)$=-0.229$ και από το cor.test μαθαίνουμε ότι η συσχέτιση είναι σημαντική (p-value=0.0178<0.05).

Για να βρούμε την σχέση μεταξύ του REM ύπνου και των κατηγορικών μεταβλητών ακολουθούμε μία διαφορετική διαδικασία. Οι κατηγορικές μεταβλητές που μας ενδιαφέρει να μελετήσουμε είναι η alcohol και caffeine, καθώς είναι αντιπροσωπευτικές των ατομικών συνηθειών του κάθε ατόμου αφού είναι στη κρίση τους η κατανάλωση του οποιουδήποτε.

Για την μελέτη του ζεύγους REM-alcohol ξεκινάμε πρώτα χωρίζοντας το δείγμα σε γκρουπ αναλόγως αν καταναλώνουν αλκοόλ ή όχι. Καταλήγουμε με δύο γκρουπ: το πρώτο το οποίο δεν καταναλώνει αλκοόλ με μέγεθος 89 ατόμων και το γκρουπ που καταναλώνει αλκοόλ με μέγεθος 17 ατόμων. Στην συνέχεια ελέγχουμε την κανονικότητα του κάθε γκρουπ. Για γκρουπ μεγέθους < 50 μας αρκεί να εφαρμόσουμε το Shapiro-Wilk τεστ, ενώ για γκρουπ με μέγεθος $>= 50$ χρειάζεται πέρα από το Shapiro-Wilk και το Kolmogorov-Smirnov. Κάνοντας τα τεστ για το κάθε γκρουπ συμπεραίνουμε ότι τηρείται η κανονικότητα και στα δύο (για το γκρουπ που καταναλώνει αλκοόλ: S-W p-value=0.2986 > 0.05, K-S p-value=0.3078 > 0.05 και για το γκρουπ που δεν καταναλώνει: S-W p-value=0.5197 > 0.05). Ύστερα, πραγματοποιώντας ένα var.test ελέγχουμε άν ο διακυμάνσεις των δύο γκρουπ είναι ίσες. Το p-value=0.448 > 0.05 άρα οι διακυμάνσεις θεωρούνται ίσες. Τέλος, κάνοντας ένα t-test ίσων διακυμάνσεων ελέγχουμε για ισότητα των μέσων των δύο γκρουπ. Το p-value του ελέγχου βγαίνει $0.0821 > 0.05$ άρα οι μέσοι των δύο γκρουπ θεωρούνται ίσοι. Συμπεραίνουμε ότι, δεν υπάρχει στατιστικά σημαντική διαφορά στο ποσοστό REM ύπνου ενός ατόμου, ανεξαρτήτως του αν καταναλώνει αλκοόλ ή όχι.

Για την μελέτη του ζεύγους REM-caffeine η μεθοδολογία δεν διαφέρει. Το δείγμα χωρίζεται ξανά σε δύο γκρουπ,

μεγέθους 24 για όσους δεν καταναλώνουν καφεΐνη και 82 για όσους καταναλώνουν. Η κανονικότητα τηρείται και στα δύο γκρουπ (για το γκρουπ που δεν καταναλώνει καφεΐνη: S-W p-value=0.9014 $>$ 0.05 και για το γκρουπ που καταναλώνει : S-W p-value=0.2963 $>$ 0.05, K-S p-value=0.5862 $>$ 0.05). Συνεχίζουμε με το var.test, όπου το p-value=0.8178 $>$ 0.05 άρα θεωρούμε ίσες διακυμάνσεις. Κλείνουμε, πάλι κάνοντας ένα t-test ίσων διακυμάνσεων όπου, από το p-value=0.8287 $>$ 0.05 του ελέγχου συμπεραίνουμε ότι οι μέσοι των δύο γκρουπ θεωρούνται ίσοι. Άρα ξανά, δεν υπάρχει στατιστικά σημαντική διαφορά στο μέσο ποσοστό REM ύπνου κάθε ατόμου, ανεξαρτήτως του αν καταναλώνει καφεΐνη ή όχι.

3.2 Σχέσεις μεταβλητών ανά necksize γκρουπ

Είδαμε τον τρόπο με τον οποίο κάθε μεταβλητή επηρεάζει το ποσοστό REM ύπνου κάθε ατόμου. Σε αυτό το κομμάτι θα δούμε εάν ο REM ύπνος επηρεάζεται από το μέγεθος λαιμού ενός ατόμου σε συνδυασμό με τις υπόλοιπες μεταβλητές. Ο διαχωρισμός, όπως αναφέρθηκε προηγουμένως, γίνεται με κριτήριο την διάμεσο του δείγματος στην τιμή 37.5cm περίμετρο λαιμού. Αφού φτιάξουμε τα δύο γκρουπ, στην συνέχεια εξάγουμε τα αναγκαία δεδομένα από το κάθε ένα όπως, το ποσοστό REM ύπνου κάθε ατόμου, το sbp τους και το AI τους καθώς και αν καταναλώνουν αλκοόλ ή καφεΐνη.

Ξεκινώντας, για το sbp και AI αρκεί να βρούμε την συσχέτιση των δύο αυτών μεταβλητών σε κάθε ένα από τα δύο γκρουπ. Βρίσκοντας το Spearman correlation μαθαίνουμε ότι: το sbp δεν είναι καθοριστικό του REM ύπνου σε κανένα από τα δύο γκρουπ ενώ, το AI είναι καθοριστικό μόνο στο γκρουπ με περίμετρο λαιμού μεγαλύτερης ή ίσης του 37.5 (correlation=$|-0.395| > 0.3$).

Για τις μεταβλητές alcohol καί caffeine πρώτα, χωρίζουμε το κάθε necksize γκρουπ βάση των επιπέδων των μεταβλητών. Καταλήγουμε με οχτώ διαφορετικά γκρουπ, 4 για το κάθε επίπεδο του necksize βάση του αν καταναλώνουν αλκοόλ ή καφεΐνη, ή όχι. Μελετώντας το πρώτο γκρουπ του necksize (αυτό με necksize $< 37.5cm$), ελέγχουμε πρώτα την κανονικότητα καθενός από τα τέσσερα γκρουπ (αφού όλα τα γκρουπ είναι < 50 μας αρκεί μόνο το S-W) και βρίσκουμε ότι η κανονικότητα τηρείται παντού (necksize $<$ 37.5: δεν καταναλώνουν αλκοόλ: S-W p-value=0.2278 $>$ 0.05, καταναλώνουν αλκοόλ: S-W p-value=0.9992 $>$ 0.05, δεν καταναλώνουν καφεΐνη: S-W p-value=0.8564 $>$ 0.05, καταναλώνουν καφεΐνη: S-W p-value=0.2121 $>$ 0.05). Ύστερα, ελέγχουμε την διασπορά μεταξύ των γκρουπ του αλκοόλ και καφεΐνη. Οι διασπορές βγαίνουν ίσες και στα δύο γκρουπ (για τα γκρουπ του αλκοόλ: var.test: p-value=0.4616 $>$ 0.05, για τα γκρουπ της καφεΐνη: var.test: p-value=0.6945 $>$ 0.05). Τέλος, μέσω t.test ίσων διακυμάνσεων ελέγχουμε για ισότητα μεταξύ των ζευγών των γκρουπ αλκοόλ και καφεΐνη (για γκρουπ αλκοόλ: p-value=0.197 $>$ 0.05, για γκρουπ καφεΐνη: p-value=0.9643 $>$ 0.05). Συμπεραίνουμε ότι, δεν υπάρχει διαφορά στο μέσο ποσοστό REM ύπνου στα άτομα με μικρότερο necksize, ανεξαρτήτως κατανάλωσης αλκοόλ ή όχι. Ομοίως και για την κατανάλωση καφεΐνη.

Προχωρώντας, ακολουθούμε την ίδια διαδικασία για το δεύτερο necksize γκρουπ (αυτό με necksize $>= 37.5cm$). Τα 4 γκρουπ είναι και εδώ < 50 άρα τεστάρουμε μόνο με S-W. Και τα δύο γκρουπ του αλκοόλ τηρούν την κανονικότητα όπως επίσης το ίδιο ισχύει για τα γκρουπ της καφεΐνη (necksize $>$ 37.5: δεν καταναλώνουν αλκοόλ: S-W p-value=02387. $>$ 0.05, καταναλώνουν αλκοόλ: S-W p-value=07454. $>$ 0.05, δεν καταναλώνουν καφεΐνη: S-W p-value=0.7811 $>$ 0.05, καταναλώνουν καφεΐνη: S-W p-value=0.5203 $>$ 0.05). Οι διασπορές ανά ζεύγη αλκοόλ και καφεΐνη βγαίνουν ίσες (για

τα γκρουπ του αλκοόλ: var.test: p-value=0.9245 > 0.05, για τα γκρουπ της καφεΐνη: var.test: p-value=0.7199 > 0.05). Ολοκληρώνοντας, τα t-test για το κάθε ζεύγος δείχνουν ότι δεν υπάρχει στατιστικά σημαντική διαφορά μεταξύ των μέσων κάθε γκρουπ (για γκρουπ αλκοόλ: p-value=0.1555 > 0.05, για γκρουπ καφεΐνη: p-value=0.7152 > 0.05). Καταλήγοντας, ούτε στα άτομα με μεγαλύτερο necksize υπάρχει διαφορά στο μέσο ποσοστό REM ύπνου, ανεξαρτήτως κατανάλωσης αλκοόλ ή όχι. Το ίδιο ισχύει και για την κατανάλωση καφεΐνη.

4 Προβλεπτικά ή Ερμηνευτικά μοντέλα

4.1 Επιλογή μοντέλου

Έχοντας ελέγξει τις σχέσεις μεταξύ των ποσοτικών και κατηγορικών μεταβλητών με την μεταβλητή REM, μπορούμε στη συνέχεια να ξεκινήσουμε την προσαρμογή ενός μοντέλου το οποίο θα μας παρέχει γνώση για το ποσοστό REM ύπνου κάθε ατόμου. Ξεκινάμε από το πλήρες μοντέλο.

Το μοντέλο: REM(Ποσοστό χρόνου γρήγορης κινήσεως ματιών)=βο(σταθερά)+β1*age(ηλικία)+β2*gender(1=γυναίκα, 0=άνδρας)+β3*BMI(Δείκτης μάζας σώματος)+β4*necksize(Περίμετρος λαιμού (cm))+β5*sbp(Συστολική πίεση αίματος (mmHg))+β6*alcohol(Χρήση αλκοόλ (1=ναι, 0=όχι))+β7*caffeine(Χρήση καφεΐνης (1=ναι, 0=όχι))+β8*AI(Δείκτης ξυπνημάτων (σχετίζεται με τον αριθμό ξυπνημάτων από τον ύπνο/ώρα ύπνου))+ε όπου ε $N(0, 0.0721^2)$.

	σταθερά	age	gender	BMI	necksize	sbp	alcohol1	caffeine	AI
B	0.1351	-0.0006	-0.0049	-0.0016	0.0044	-0.0005	-0.0388	0.0102	-0.0013
p-value	0.1705	0.1205	0.8046	0.4135	0.1412	0.3265	0.0574	0.5503	0.0170

Πίνακας 4: Πίνακας τιμών παραμέτρων

Για την σταθερή παράμετρο ισχύουν τα εξής:Το βο, το οποίο είναι η σταθερά, έχει τιμή 0.1351. Αυτό σημαίνει πώς, το αναμενόμενο ποσοστό REM ύπνου για ένα άτομο ηλικίας 0 χρόνων, φύλου άντρα με BMI=0, necksize=0, sbp=0, AI=0 που ταυτόχρονα δεν χρησιμοποιεί αλκοόλ και καφεΐνη θα είναι 13.51%.

Για τις υπόλοιπες παραμέτρους ισχύουν ότι: Για το β1, δεδομένου ότι όλες οι υπόλοιπες μεταβλητές μένουν σταθερές τότε με αύξηση ηλικίας μίας μονάδας έχουμε αναμενόμενη μείωση του ποσοστού REM κατά 0.06%.

Για το β2, δεδομένου ότι όλες οι υπόλοιπες μεταβλητές μένουν σταθερές τότε υπάρχει αναμενόμενη μείωση του ποσοστού REM κατά 0.4978% εφόσον το άτομο είναι γυναίκα.

Για το β3, υπό τις ίδιες συνθήκες, παρατηρείται αναμενόμενη μείωση του ποσοστού REM ύπνου κατά 0.1613% για κάθε αύξηση του BMI κατά μία μονάδα.

Για το β4, με τις υπόλοιπες μεταβλητές σταθερές, υπάρχει αναμενόμενη αύξηση του ποσοστού REM κατά 0.4451% με κάθε αύξηση του necksize κατά 1cm.

Για το β5, με τα υπόλοιπα σταθερά, έχουμε αναμενόμενη μείωση του ποσοστού REM κατά 0.0513% με κάθε αύξηση του sbp κατά μία μονάδα μέτρησής του.

Για τα β6 (αλκοόλ) και β7 (καφεΐνη), με όλες τις μεταβλητές εκτός της αναφερόμενης σταθερές, υπάρχει αντίστοιχα

αναμενόμενη μείωση του ποσοστού REM κατά 3.88% και αναμενόμενη αύξηση κατά 1.02% δεδομένου χρήσης τους.

Για το β8, υπό τις ίδιες συνθήκες, παρατηρούμε αναμενόμενη μείωση του ποσοστού REM ύπνου κατά 0.132% για αύξηση του AI κατά μία μονάδα.

Το πλήρες μοντέλο τηρεί όλες τις προϋποθέσεις ενός μοντέλου παλινδρόμησης (κανονικότητα καταλοίπων, ομοσκεδαστικότητα καταλοίπων, ανεξαρτησία και γραμμικότητα). Παρόλα αυτά, δεν γνωρίζουμε αν το μοντέλο μας είναι το βέλτιστο δυνατό. Το $adjR^2 = 0.10$ μας υποδηλώνει ότι τα δεδομένα μας δεν προσαρμόζονται καλά από το μοντέλο ενώ υπάρχουν μεταβλητές οι οποίες δεν είναι στατιστικά σημαντικές. Για να βρούμε το βέλτιστο μοντέλο θα χρησιμοποιήσουμε το BIC κριτήριο σε συνδυασμό με το $adjR^2$ μέσω της stepwise μεθοδολογίας επιλογής μοντέλου. Ύστερα από υλοποίηση της μεθοδολογίας το μοντέλο στο οποίο καταλήγουμε είναι το μοντέλο με μοναδική μεταβλητή το AI. Ωστόσο το μοντέλο αυτό έχει πολύ μικρό $adjR^2$. Χρησιμοποιώντας την stepwise μεθοδολογία με AIC το προτεινόμενο μοντέλο είναι αυτό με μεταβλητές τις: age, necksize, alcohol και AI. Αναλύοντας μοντέλα με κάθε συνδυασμό των τεσσάρων αυτών μεταβλητών καταλήγουμε στα εξής: Το μοντέλο και με τις 4 μεταβλητές έχει το μεγαλύτερο $adjR^2$. Ωστόσο έχει από τα μικρότερα BIC. Το αντίθετο ισχύει για το μοντέλο μόνο με την μεταβλητή AI.

Δεδομένου ότι η ανάλυση γίνεται σε ιατρικά δεδομένα τα οποία έχουν μεγάλη μεταβλητότητα, είναι προτιμότερο να διαλέξουμε το μοντέλο το οποίο περιγράφει την μεταβλητότητα αυτή καλύτερα, συγκριτικά με τα υπόλοιπα. Ακόμη, όπως αναφέρεται στην έρευνα του Ehlers[2] η ηλικία ενθαρρύνεται σαν ύπαρξη μεταβλητής σε μοντέλα ανάλυσης ύπνου ενώ βάση της έρευνας του Cizza[1], το ίδιο ισχύει για την περίμετρο λαιμού καθώς, αποτελεί παράγοντα που συνεισφέρει στην ύπαρξη οξείας άπνοιας[7]. Με βάση τα παραπάνω, θεωρούμε το μοντέλο με μεταβλητές τις: age, necksize, alcohol και AI, το πιο κατάλληλο για την ανάλυση.

REM=βο+β1*age+β2*necksize+β3*alcohol+β4*AI+ε, όπου ε $N(0, 0.0724^2)$

(Η κανονικότητα των καταλοίπων θα αποδειχθεί αργότερα.)

	σταθερά	age	necksize	alcohol1	AI
B	0.09209	-0.0007	0.0029	-0.0298	-0.0014
p-value	0.1508	0.0996	0.0843	0.1273	0.0057

Πίνακας 5: Πίνακας τιμών παραμέτρων επιλεγμένου μοντέλου

Ομοίως με πριν, δεδομένου ότι κάθε άλλη μεταβλητή παραμένει σταθερή εκτός από την αναφερόμενη, τότε για αύξηση μίας μονάδας των μεταβλητών age, necksize και AI έχουμε αναμενόμενη μεταβολή του REM ύπνου κατά: -0.0007, 0.0029 και -0.0014 αντίστοιχα ενώ με τις υπόλοιπες μεταβλητές σταθερές, εφόσον υπάρχει χρήση αλκοόλ έχουμε αναμενόμενη μεταβολή κατά -0.0298. Τέλος, για τιμή μηδέν για όλες τις μεταβλητές, η σταθερά είναι 0.092.

Έχοντας υλοποιήσει την stepwise μεθοδολογία μαθαίνουμε ότι: το BIC του αρχικού (πλήρες) μοντέλου ήταν -218.52. Το BIC του μοντέλου στο οποίο καταλήξαμε είναι -233.80. Παρατηρείται επίσης μικρή βελτίωση στο $adjR^2$ καθώς τώρα το $adjR^2 = 0.11$ (πριν ήταν 0.10). Ακόμη, ύστερα από έλεγχο με την συνάρτηση vif στην R βλέπουμε πώς στο μοντέλο μας δεν υπάρχει πρόβλημα πολυσυγγραμμικότητας μεταξύ των μεταβλητών.

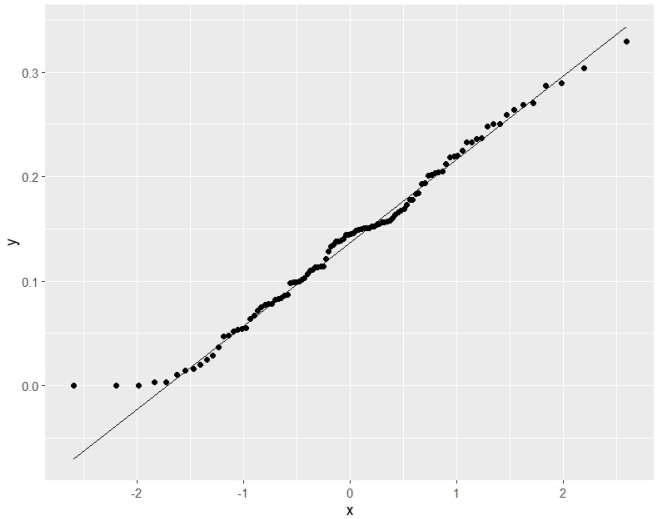
Παρατηρούμε πώς, η μεταβλητές age, necksize και alcohol εξακολουθούν να είναι στατιστικά μη-σημαντικές. Παρόλα αυτά, όπως αναφέρθηκε προηγουμένως, η προσθήκη ηλικίας και περιμέτρου λαιμού συνιστάται για τέτοιου είδους μοντέλα. Ακόμα, όπως αναφέρει μία έρευνα από το National Library of Sleep[6], η επίδραση του αλκοόλ στον REM ύπνο ενδέχεται να είναι μεγαλύτερη από ότι προηγουμένως πιστευόταν. Στην έρευνα, οι ερευνητές χορήγησαν όμοια ποσότητα αλκοόλ σε κάθε εθελοντή, περίπου 30-60 λεπτά πριν την ώρα ύπνου τους. Παρατηρήθηκε ότι, στο πρώτο μισό του ύπνου, ο REM ύπνος είχε μειωθεί σε σύγκριση με το δεύτερο μισό του ύπνου, καθώς η επίδραση του αλκοόλ κορυφώνεται στο πρώτο μισό ενώ ύστερα υποχωρεί. Δηλαδή, στο σύνολο όλου του ύπνου παρατηρείται μείωση του REM ύπνου ενώ αναφέρεται ότι, ο ρόλος που κατέχει το αλκοόλ στην μείωσή του υποτιμάται. Παρόλα αυτά, η μέθοδος με την οποία προτείνεται πιο διεξοδική έρευνα δεν είχε διεξαχθεί ακόμη. Αυτό όμως δεν πρέπει να φέρει προβληματισμό αφού η αναφερόμενη μέθοδος, δεν συνεπάγεται ρεαλιστικές συνθήκες καθώς, προτείνεται χορήγηση αλκοόλ σε κάθε εθελοντή κατά τη διάρκεια ύπνου, κάτι αδύνατο υπό άλλοτε φυσιολογικές συνθήκες. Με βάση το παραπάνω, η προσθήκη κατανάλωσης αλκοόλ σαν μεταβλητή στο μοντέλο θεωρείται ευπρόσδεκτη.

4.2 Έλεγχος μοντέλου

Όπως και πριν, έτσι και τώρα πρέπει να ελέγξουμε αν το επιλεγμένο μοντέλο τηρεί τις προϋποθέσεις ενός μοντέλου παλινδρόμησης, ξεκινώντας πρώτα με την κανονικότητα των καταλοίπων.

4.2.1 Κανονικότητα

Για να ελέγξουμε κανονικότητα μπορούμε να χρησιμοποιήσουμε διαγράμματα σε συνδυασμό με ελέγχους για τα κατάλοιπα. Χρησιμοποιώντας την βιβλιοθήκη ggplot2 αποκτάμε το εξής διάγραμμα για τα κατάλοιπα:



Σχήμα 1: Q-Q plot των καταλοίπων

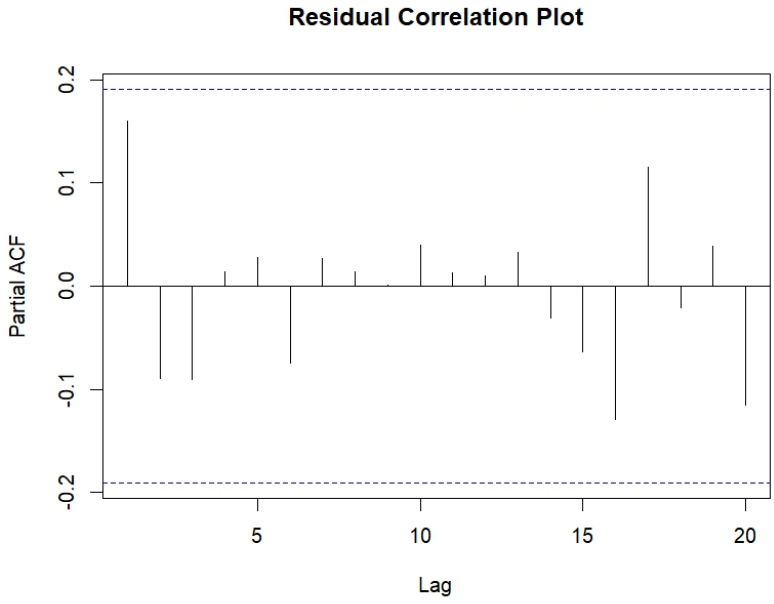
Τα κατάλοιπα φαίνονται να είναι κανονικά. Κάνοντας ένα Lillie (K-S) τεστ επιβεβαιώνεται η υπόθεσή μας (p-value=0.4422 $>$ 0.05).

4.2.2 Ομοσκεδαστικότητα

Για την ομοσκεδαστικότητα μπορούμε να κοιτάξουμε τα διαγράμματα των fitted καταλοίπων με τα κατάλοιπα, την ρίζα των απόλυτων τιμών των καταλοίπων και με το τετράγωνο των καταλοίπων αντίστοιχα. Από τα διαγράμματα βλέπουμε μερικά κατάλοιπα εκτός ορίων. Παρόλα αυτά δεν μπορούμε να είμαστε σίγουροι για το τι ισχύει χωρίς το κατάλληλο τεστ. Πραγματοποιώντας ένα Levene τεστ ανά τεταρτημόρια βρίσκουμε ότι, η διακύμανση βγαίνει ίση άρα τηρείται η ομοσκεδαστικότητα (p-value=0.1138 $>$ 0.05). Τέλος, πραγματοποιώντας και ένα ncv (non-constant error variance) τεστ επιβεβαιώνεται και πάλι η ομοσκεδαστικότητα (p-value=0.0566>0.05).

4.2.3 Ανεξαρτησία

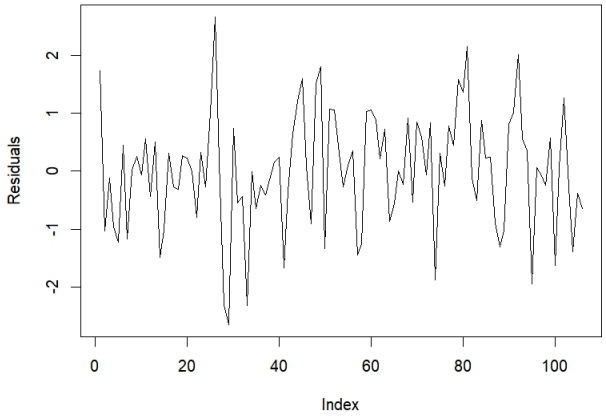
Για την ανεξαρτησία μπορούμε να κοιτάξουμε ένα AR (autoregressive) plot (pacf plot) το οποίο θα μας δείχνει αν υπάρχουν στατιστικά σημαντικές συσχετίσεις σε σύγκριση με το παρόν (Το παρόν αντιπροσωπεύεται από το $lag = 0$) καθώς και ένα residual plot από το οποίο θα μπορέσουμε να εντοπίσουμε αν υπάρχει κάποιο μοτίβο στα κατάλοιπα μας.



Σχήμα 2: PACF plot για συσχετίσεις μεταξύ lag=0 με άλλα lags

Παρατηρούμε ότι, καμία από τις κάθετες γραμμές (οι οποίες αντιπροσωπεύουν την συσχέτιση του συγκεκριμένου lag με το lag=0) δεν βγαίνει εκτός των οριοθετημένων μπλε γραμμών. Αυτό σημαίνει ότι δεν υπάρχει σημαντική συσχέτιση σε κανένα lag άρα, καμία μελλοντική στιγμή δεν επηρεάζεται από το παρόν.

Στην συνέχεια το plot των καταλοίπων:

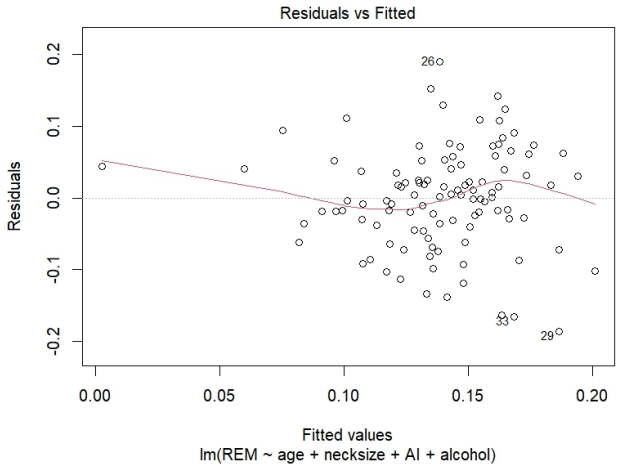


Σχήμα 3: Plotted κατάλοιπα

Από το παραπάνω διάγραμμα δεν φαίνεται να υπάρχει κάποιο μοτίβο στην κατανομή των καταλοίπων μας. Βάση των παραπάνω διαγραμμάτων μπορούμε να συμπεράνουμε ότι, τα κατάλοιπα μας είναι ανεξάρτητα μεταξύ τους. Τέλος, ένα Darbin Watson τεστ επαληθεύει το συμπέρασμά μας (p-value=0.07 > 0.05)

4.2.4 Γραμμικότητα

Προκειμένου να ελέγξουμε την γραμμικότητα πρώτα, φτιάχνουμε το διάγραμμα των καταλοίπων συναρτήσει των προσαρμοσμένων τιμών. Αυτό που επιθυμούμε να δούμε είναι μια γραμμή όσο πιο όμοια σε ευθεία, να περνάει ενδιάμεσα από τα δεδομένα.

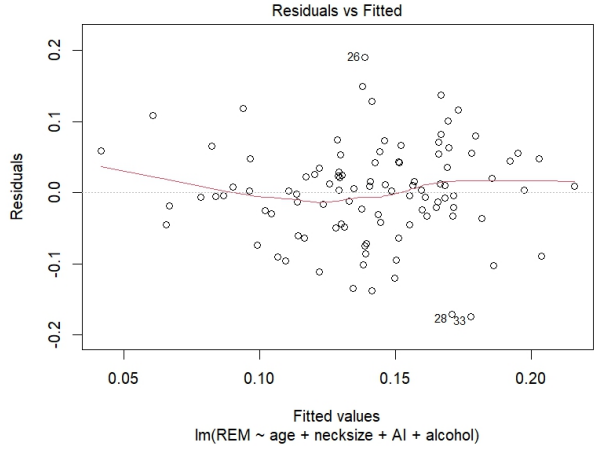


Σχήμα 4: Plot καταλοίπων με προσαρμοσμένων τιμών

Όπως φαίνεται από το παραπάνω διάγραμμα, ο τρόπος με τον οποίο είναι διατεταγμένα τα δεδομένα δεν περιγράφεται καλύτερα από ευθεία γραμμή. Άρα δεν τηρείται η γραμμικότητα.

Διερευνώντας την σχέση μεταξύ των ανεξάρτητων ποσοτικών μεταβλητών με της εξαρτημένης μεταβλητής βλέπουμε ότι στο διάγραμμα REM AI (βλέπε παράρτημα σχήμα 10) μια τιμή φαίνεται να απέχει πολύ από τις υπόλοιπες. Λόγω αυτής της παρατήρησης επιθυμούμε να ελέγξουμε για τυχών ακραίες τιμές που μπορεί να επηρεάζουν την γραμμικότητα. Αυτό το ελέγχουμε μέσω ενός Cooks distance plot (βλέπε παράρτημα σχήμα 11). Παρατηρούμε ότι υπάρχουν ακραίες τιμές, μια εκ των οποίων περιέχει την τιμή της μεταβλητής AI που απείχε πολύ από τις υπόλοιπες. Εφόσον το δείγμα μας είναι μικρό τότε δεν θα αφαιρέσουμε όλες τις ακραίες τιμές αλλά θα αφαιρούμε σταδιακά μέχρι να παρατηρήσουμε βελτίωση. Ξεκινάμε αφαιρώντας τις τέσσερις πιο ακραίες και ύστερα ελέγχοντας τα χαρακτηριστικά του μοντέλου.

Το δείγμα αποτελείται πλέον από 102 σειρές δεδομένων. Το $adjR^2$ έχει βελτιωθεί καθώς από 0.11 τώρα $adjR^2 = 0.16$ ενώ μικρή βελτίωση έχουμε και στο BIC (από -233.80, τώρα -233.93). Η κανονικότητα τηρείται και πάλι (K-S p-value=0.4757 $>$ 0.05). Το Levene τεστ ανά τεταρτημόρια επιβεβαιώνει την ομοσκεδαστικότητα (p-value=0.4959 $>$ 0.05) όπως επίσης επιβεβαιώνει και το ncv τεστ (p-value=0.3786 $>$ 0.05). Το Darbin Watson τεστ επαληθεύει την ανεξαρτησία (p-value=0.352 $>$ 0.05) ενώ φαίνεται να υπάρχει βελτίωση στην γραμμικότητα (βλέπε σχήμα 5)



Σχήμα 5: Plot καταλοίπων με προσαρμοσμένων τιμών αφού αφαιρέσαμε τέσσερις ακραίες τιμές

Στο μοντέλο εξακολουθούν να υπάρχουν ακραίες τιμές (βλέπε παράρτημα σχήμα 12). Παρόλα αυτά στατιστικά σημαντική μεταβλητή μαζί με την AI θεωρείται και η necksize. Αυτή η παρατήρηση υπονοεί πως, ο λόγος που οι μεταβλητές εκτός της AI δεν θεωρούνταν στατιστικά σημαντικές προηγουμένως ήταν λόγω του μικρού δείγματος σε συνδυασμό με τις ακραίες τιμές. Γενικά, τα ιατρικά δεδομένα έχουν μεγάλη μεταβλητότητα η οποία ενδεχομένως να περιγραφόταν καλύτερα δεδομένου μεγαλύτερου δείγματος. Εφόσον όμως το δείγμα είναι μικρό τότε αφαιρώντας τα τέσσερα μεγαλύτερα outliers (τα οποία και αυτά ίσως να περιγράφονταν με περισσότερα δεδομένα) βελτιώνουμε το μοντέλο αρκετά χωρίς να πρέπει να αφαιρέσουμε παραπάνω δεδομένα και να μικρύνουμε το δείγμα μας περαιτέρω.

Το τελικό μοντέλο τηρεί όλες τις προϋποθέσεις. (BIC=-233.93, $adjR^2 = 0.16$)

5 Συμπεράσματα και Συζήτηση

Παρότι το τελικό μοντέλο στο οποίο καταλήξαμε δεν εξηγεί καλά την μεταβλητότητα, όπως συμπεραίνουμε από το χαμηλό $adjR^2$, την εξηγεί καλύτερα από οποιοδήποτε άλλο μοντέλο με οποιονδήποτε άλλο συνδυασμό των τεσσάρων μεταβλητών. Ακόμη, έχει προσαρμόσει τα δεδομένα σε ικανοποιητικό βαθμό όπως ενδείκνυται από το χαμηλότερο BIC συγκριτικά με το πλήρες μοντέλο. Σύμφωνα λοιπόν με το τελικό μοντέλο, οι κύριοι παράγοντες από τους οποίους επηρεάζεται ο REM ύπνος αποτελούνται τόσο από ατομικές επιλογές όπως είναι η χρήση του αλκοόλ όσο και από ανεξέλεγκτους παράγοντες όπως η ηλικία. Το AI εξαρτάται τόσο από την ηλικία όσο και από τις ατομικές συνήθειες του κάθε ατόμου, που ως παράδειγμα έχουν σαν αποτέλεσμα την παχυσαρκία[4] και αυτός είναι και ο λόγος για τον οποίο μεταβλητές όπως BMI και sbp δεν κατέληξαν στο μοντέλο, καθώς περιγράφονται από το AI.

Με την ύπαρξη μίας τέτοιας έρευνας οι άνθρωποι, μπορούν να μείνουν ενημερωμένοι για τις διάφορες αιτίες όπου ενδέχεται να επηρεάζουν την ποιότητα του ύπνου τους, οι οποίες σαν αποτέλεσμα πιθανόν να καθιστούν δύσκολη την καθημερινότητά τους. Ταυτόχρονα, μπορεί να βοηθήσει τα άτομα τα οποία ήδη πάσχουν από έλλειψη REM ύπνου στο να πάρουν τα κατάλληλα μέτρα προκειμένου, να βελτιώσουν την κατάστασή τους και συγχρόνως να αποφύγουν ενδεχόμενες πολυπλοκότητες[3] τις οποίες συνεπάγεται η συγκεκριμένη έλλειψη.

References

[1] Giovanni Cizza, Lilian de Jonge, Paolo Piaggi, Megan Mattingly, Xiongce Zhao, Eliane Lucassen, Kristina I Rother, Anne E Sumner, Gyorgy Csako, and NIDDK Sleep Extension Study. Neck circumference is a predictor of metabolic syndrome and obstructive sleep apnea in short-sleeping obese men and women. *Metabolic syndrome and related disorders*, 12(4):231–241, 2014.

[2] Cindy L Ehlers and David J Kupfer. Effects of age on delta and rem sleep parameters. *Electroencephalography and clinical neurophysiology*, 72(2):118–125, 1989.

[3] Susan M Harding. Complications and consequences of obstructive sleep apnea. *Current opinion in pulmonary medicine*, 6(6):485–489, 2000.

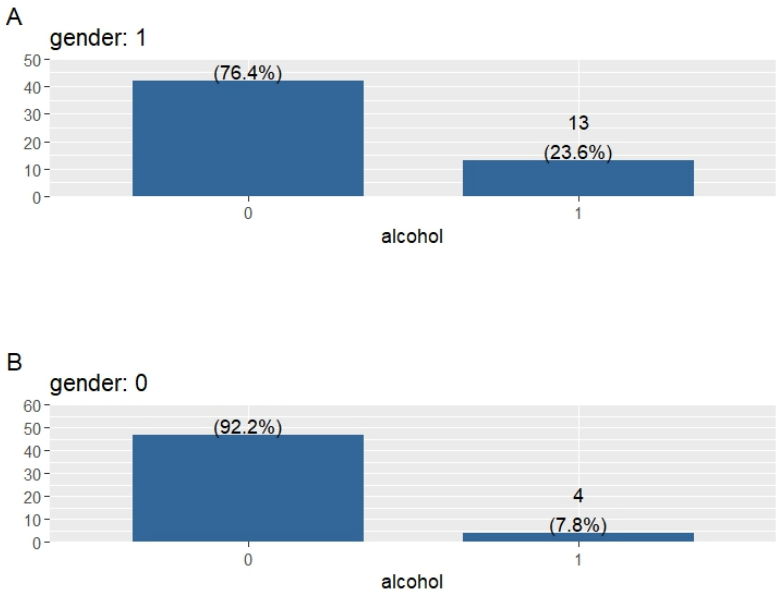
[4] Matthew L Ho and Steven D Brass. Obstructive sleep apnea. *Neurology international*, 3(3):e15, 2011.

[5] Kathy L Nelson, Jean E Davis, and Cynthia F Corbett. Sleep quality: An evolutionary concept analysis. In *Nursing forum*, volume 57, pages 144–151. Wiley Online Library, 2022.

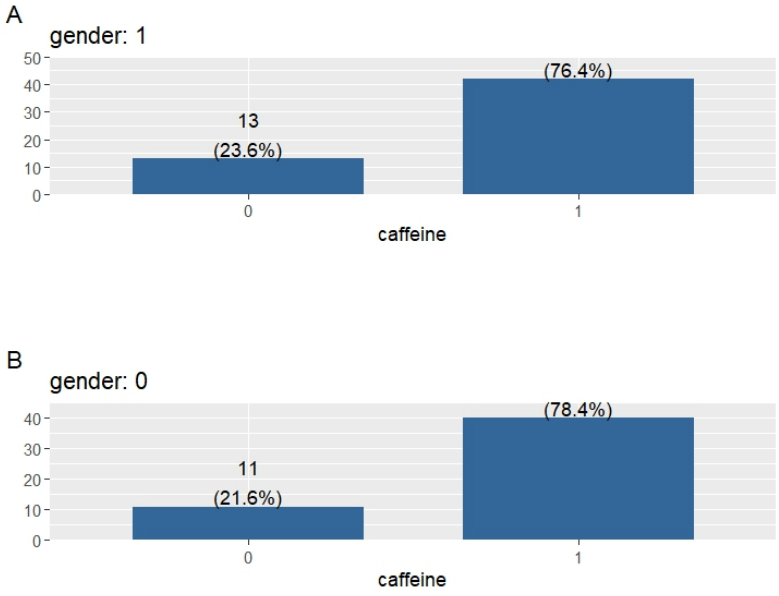
[6] Timothy Roehrs and Thomas Roth. Sleep, sleepiness, and alcohol use. *Alcohol Research & Health*, 25(2):101, 2001.

[7] Andrew W Varga and Babak Mokhlesi. Rem obstructive sleep apnea: risk for adverse health outcomes and novel treatments. *Sleep and Breathing*, 23:413–423, 2019.

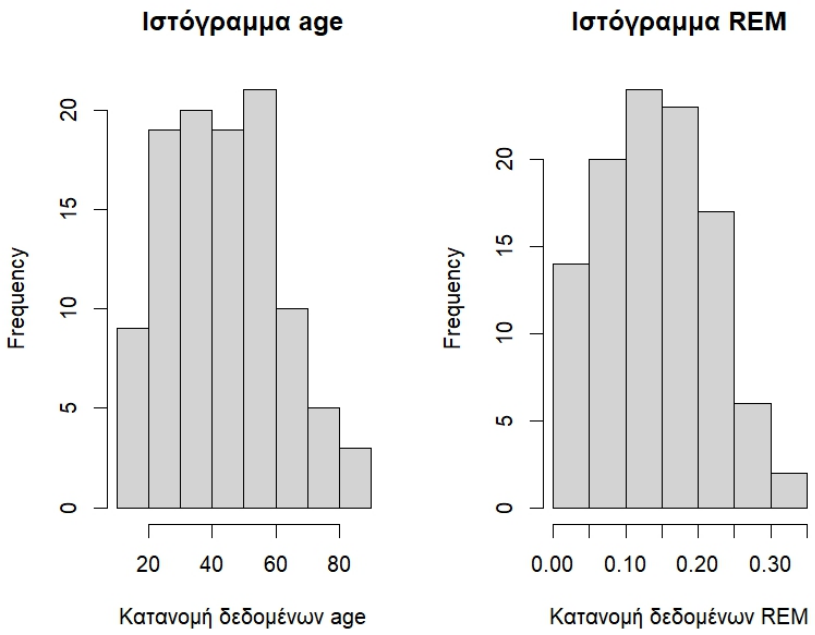
6 Παράρτημα



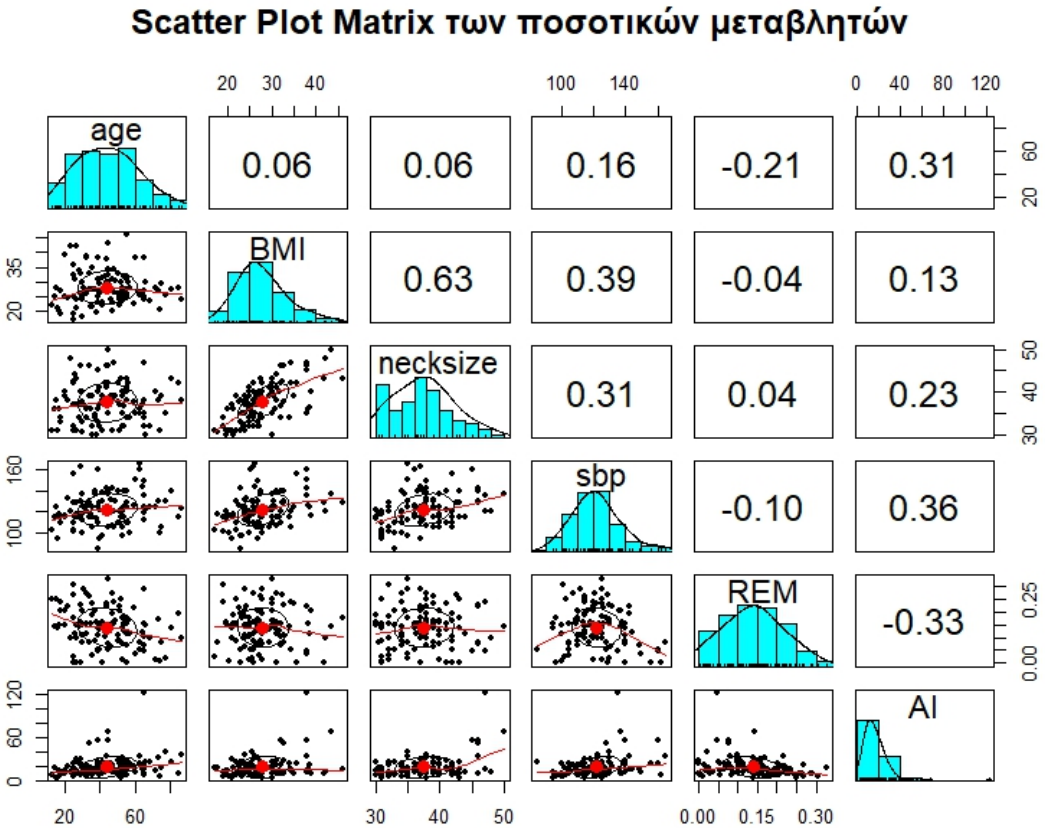
Σχήμα 6: Barplot κατανάλωσης αλκοόλ ανά φύλο.



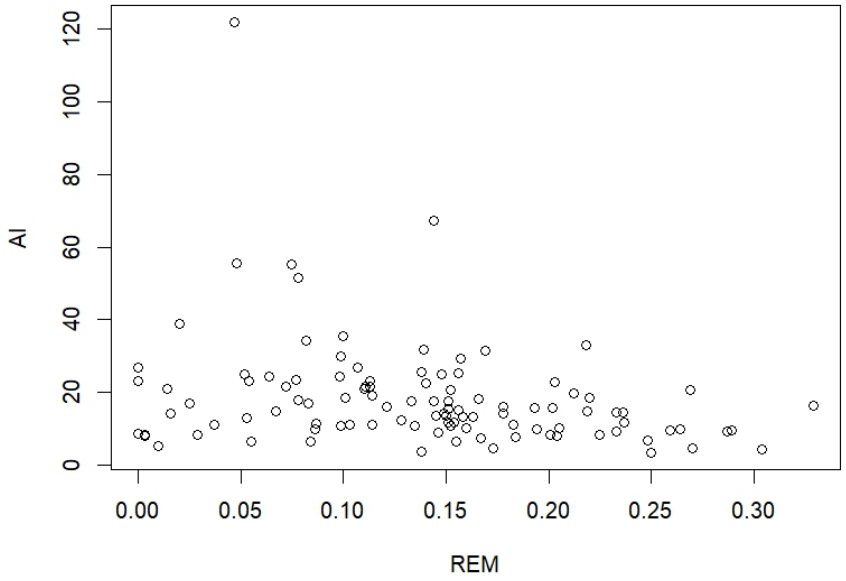
Σχήμα 7: Barplot κατανάλωσης καφεΐνης ανά φύλο.



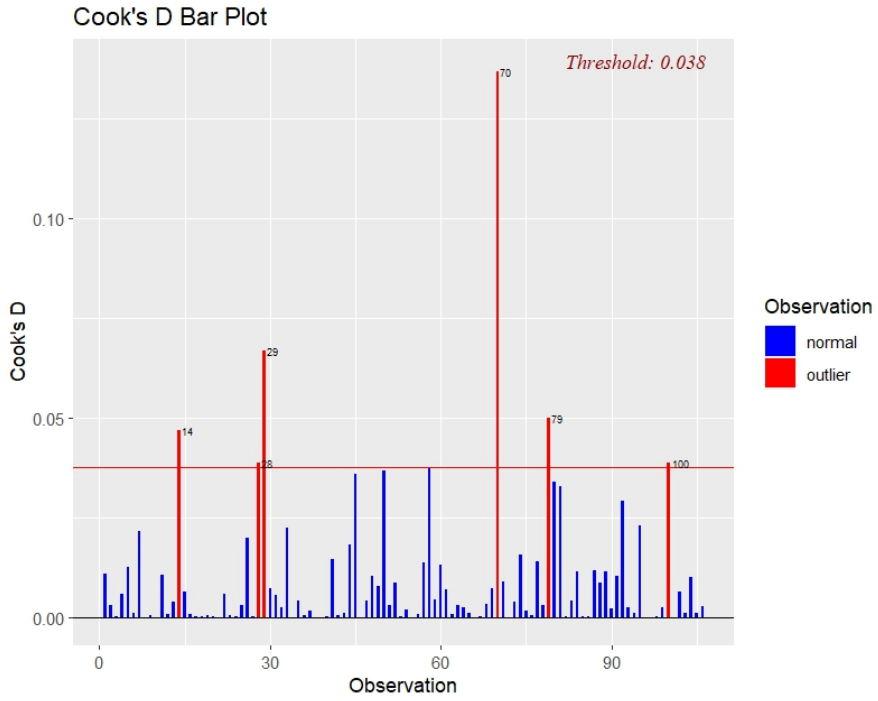
Σχήμα 8: Ιστογράμματα κανονικών μεταβλητών.



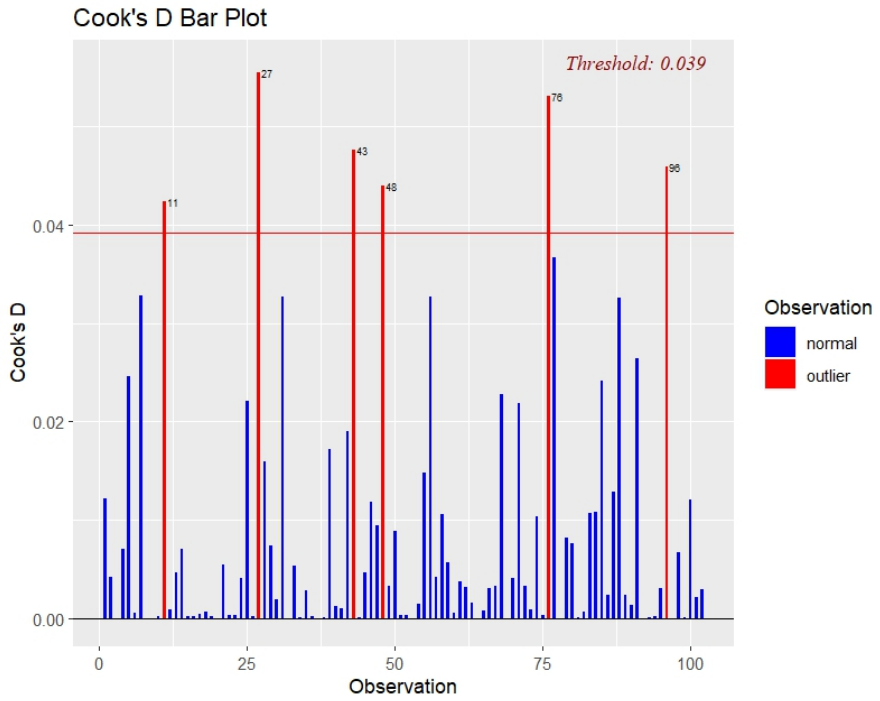
Σχήμα 9: Scatter Plot Matrix των ποσοτικών μεταβλητών.



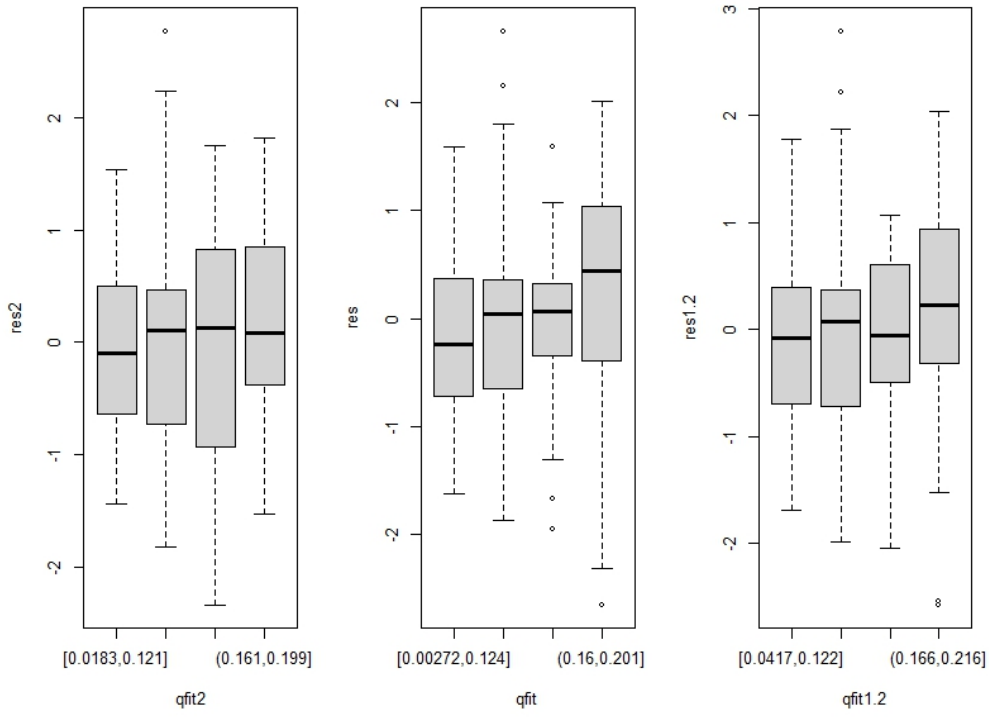
Σχήμα 10: Δεδομένα AI συναρτήσει REM.



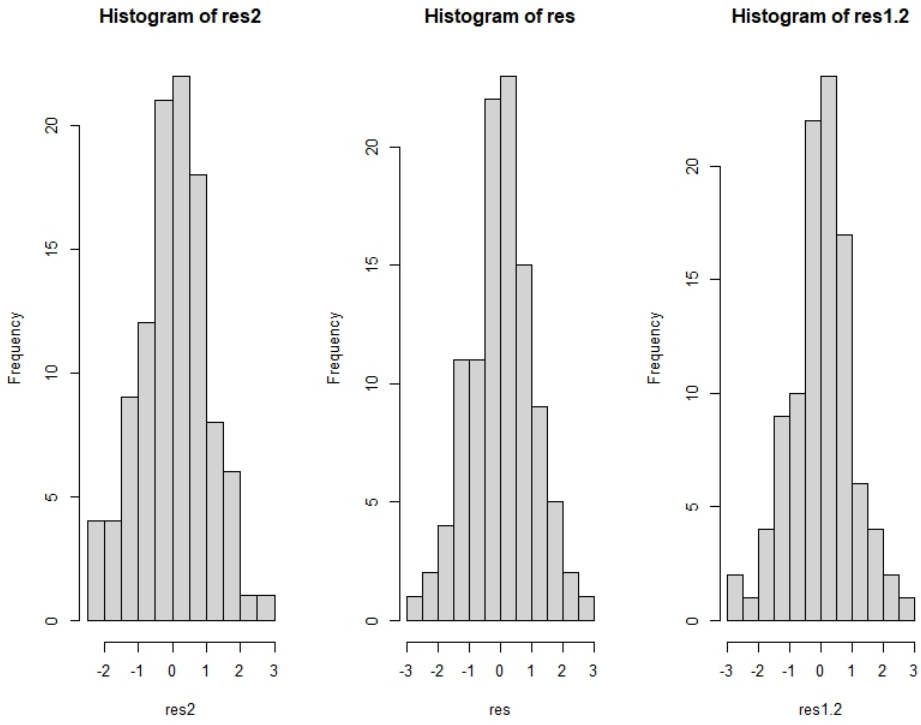
Σχήμα 11: Cooks distance plot για έλεγχο ακραίων τιμών μοντέλου.



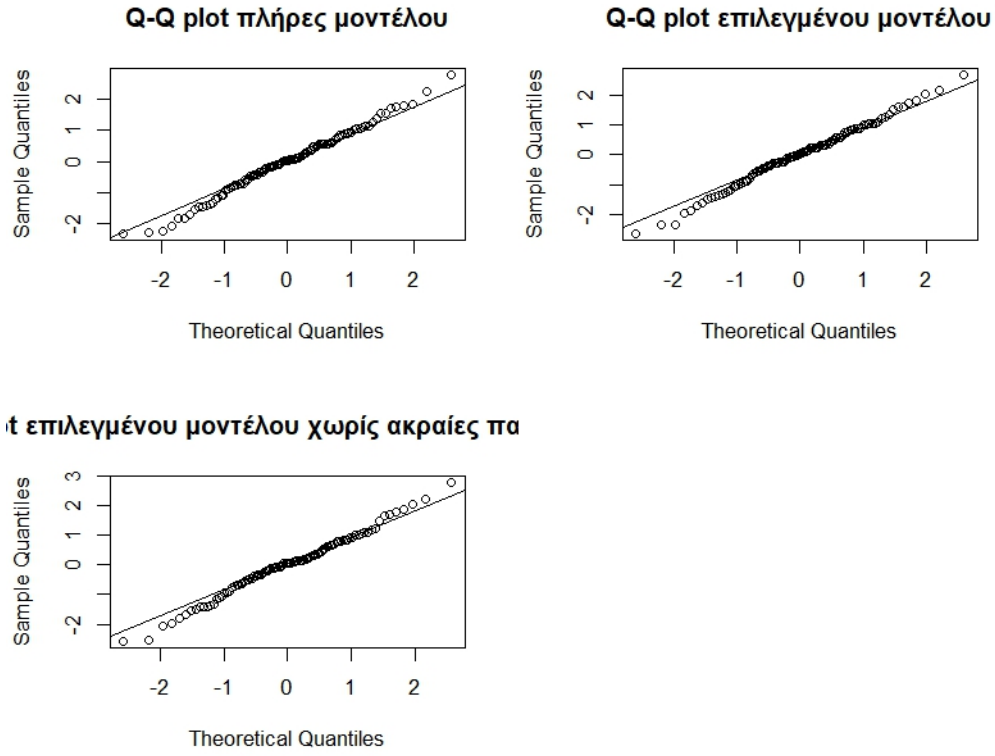
Σχήμα 12: Cooks distance plot για έλεγχο ακραίων τιμών μοντέλου αφού αφαιρέσαμε 4 ακραίες τιμές.



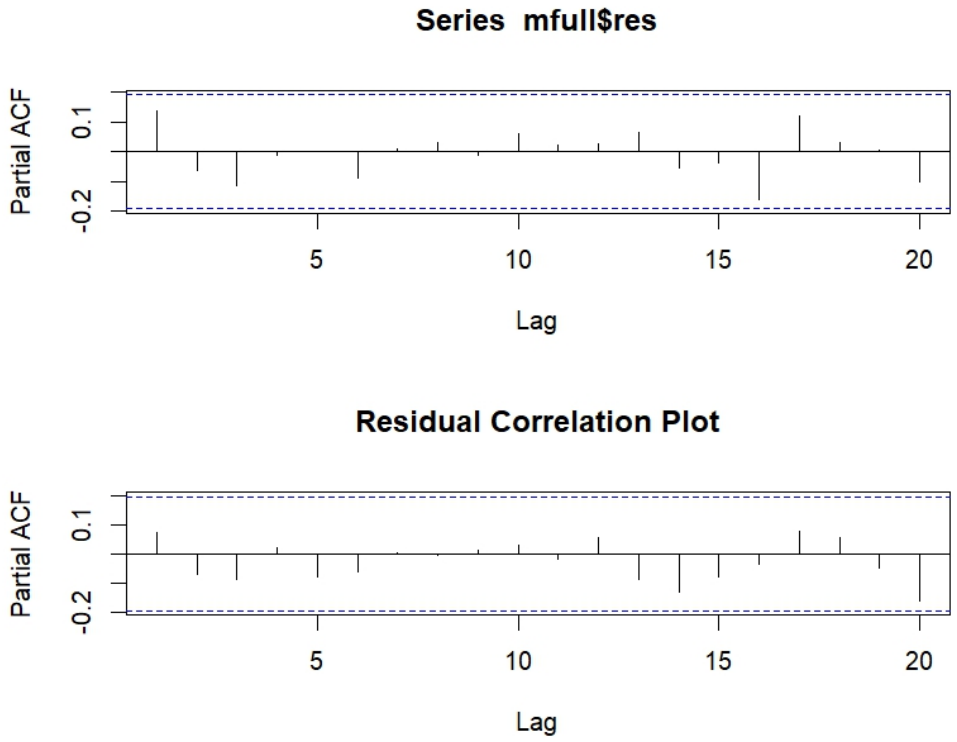
Σχήμα 13: Box plots πλήρες, επιλεγμένου και επιλεγμένου χωρίς 4 ακραίες τιμές μοντέλων αντίστοιχα.



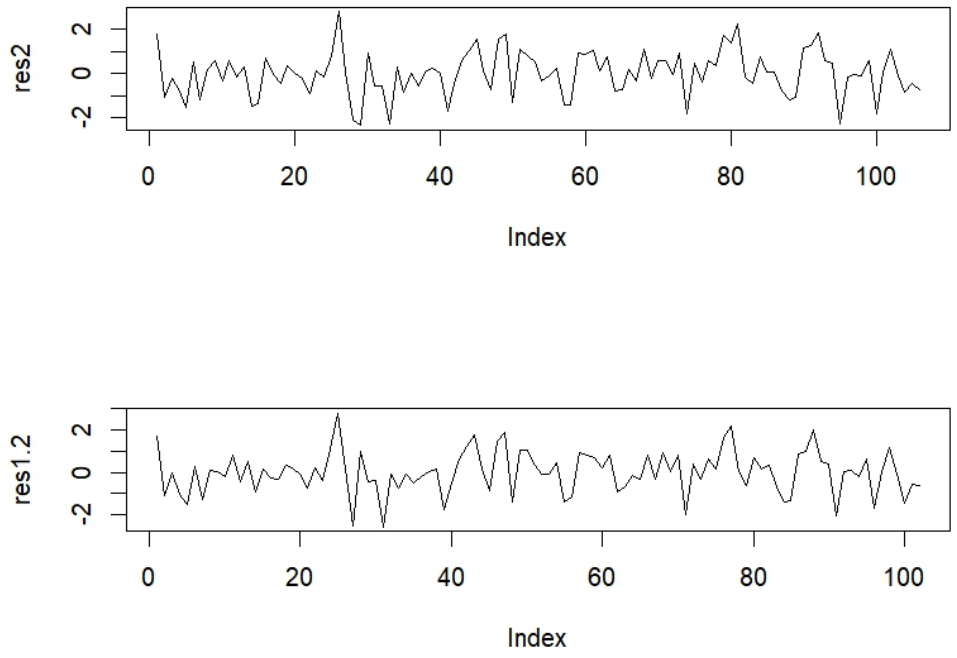
Σχήμα 14: Ιστογράμματα καταλοίπων πλήρους, επιλεγμένου και επιλεγμένου χωρίς 4 ακραίες τιμές μοντέλων αντίστοιχα.



Σχήμα 15: Q-Q plot καταλοίπων πλήρους, επιλεγμένου και επιλεγμένου χωρίς 4 ακραίες τιμές μοντέλων αντίστοιχα.



Σχήμα 16: PACF plots του πλήρες (πάνω) και επιλεγμένου ύστερα από αφαίρεση ακραίων τιμών (κάτω).



Σχήμα 17: Plotted κατάλοιπα πλήρες μοντέλου (πάνω) και επιλεγμένου ύστερα από αφαίρεση ακραίων τιμών (κάτω).